UNIVERSIDAD COMPLUTENSE DE MADRID

Máster Data Science, Big Data & Business Analytics

TRABAJO FIN DE MÁSTER

Predicción de la severidad de accidentes de tráfico mediante técnicas de Machine Learning y su integración como herramienta de apoyo a la decisión

Autor/a:

Jose Manuel Ríos Zorrilla

Curso 2025–2026

ÍNDICE

0. Introducción

1. Análisis Exploratorio de Datos

    1.1 Diagnóstico general del dataset

    1.2 Eliminación inicial de variables

    1.3 Tratamiento general de valores nulos

2. Limpieza y transformación de variables

3. Modelado

    3.1 Modelo baseline trivial como referencia mínima

    3.2 Modelo inicial - LightGBM

    3.3 Modelos alternativos

        3.3.1 XGBoost

        3.3.2 CatBoost

    3.4 Comparativa modelos y selección del modelo candidato

    3.5 Optimización modelo

    3.6 Ajuste del umbral de decisión

4. Interpretabilidad del modelo mediante SHAP

5. Productivización del modelo

    5.1 Persistencia del modelo y consistencia de entrada

    5.2 Interfaz de consumo

    5.3 Caso práctico de uso

    5.4 Validación post-prueba

    5.5 Consideraciones para entorno operativo

6. Conclusión

7. Bibliografía y Referencias

0. Introducción

El análisis de la siniestralidad vial constituye un área de gran interés tanto desde el punto de vista de la seguridad pública como desde una perspectiva operativa y de gestión del riesgo. En particular, disponer de herramientas que permitan anticipar la gravedad potencial de un accidente en el momento inicial de su registro puede resultar de gran utilidad para organismos de emergencia, administraciones públicas y entidades aseguradoras.

En un contexto operativo, esta capacidad predictiva puede apoyar el proceso de triaje inicial, permitiendo priorizar de forma temprana el envío de recursos sanitarios (ambulancia) frente a intervenciones de carácter logístico o material (grúa), cuando la información disponible es aún limitada.

En este Trabajo Fin de Máster se aborda un problema de clasificación supervisada, cuyo objetivo es predecir si un accidente de tráfico conllevará daños exclusivamente materiales o si, por el contrario, implicará daños físicos (lesiones o fallecimientos). La predicción se realiza utilizando únicamente información que estaría razonablemente disponible en las fases iniciales de notificación del accidente, evitando de forma explícita el uso de variables que dependen del resultado final del siniestro o de evaluaciones posteriores, con el fin de garantizar un enfoque realista y aplicable en un entorno productivo.

Los registros proceden del sistema oficial de reporte de accidentes de Maryland (ACRS), utilizado por los cuerpos policiales para documentar colisiones de tráfico.

Fuente de datos descargados octubre 2025:
https://catalog.data.gov/dataset/crash-reporting-drivers-data

El desarrollo del proyecto se ha realizado en Google Colab.

1. Análisis exploratorio de datos

1.1 Diagnóstico general del dataset

Se realizó una revisión inicial del dataset con el objetivo de (i) evaluar la calidad y completitud de la información disponible y (ii) anticipar riesgos de modelado asociados a variables poco estables. En esta etapa se analizaron patrones de valores ausentes y la cardinalidad de las variables, identificando campos con pérdida de información significativa y variables con comportamiento potencialmente identificativo. Este diagnóstico permite establecer un punto de partida consistente para la depuración y evita incorporar al pipeline señales espurias o poco generalizables.

1.2 Eliminación inicial de variables

A partir del diagnóstico anterior se aplicó una depuración preliminar basada en criterios estructurales, orientada a mejorar la robustez del proceso de modelado y reducir el riesgo de sobreajuste. En esta fase se excluyeron:

Variables identificativas o de cardinalidad extremadamente alta que no describen un patrón generalizable del accidente y pueden inducir aprendizaje espurio.

Variables con ausencia masiva, donde la información disponible no permite un uso fiable sin introducir supuestos fuertes mediante imputación.

Esta depuración no pretende sustituir una selección de variables basada en rendimiento, sino asegurar una base estable sobre la que realizar transformaciones posteriores y comparar modelos de forma consistente.

1.3 Tratamiento general de valores nulos

Tras la depuración inicial, se adoptó un criterio general para tratar valores ausentes priorizando la conservación de registros y la trazabilidad del dato. En variables categóricas, los valores faltantes se representaron mediante una categoría explícita (UNKNOWN), interpretando la ausencia como "información no registrada". Esta decisión evita descartar observaciones y permite que el modelo capture patrones asociados a la falta de información sin imponer imputaciones artificiales ni introducir supuestos numéricos.

2. Limpieza y transformación de variables

Con el fin de estructurar el proceso de selección y preparación de variables, se definió una tipología de variables basada en los principales riesgos metodológicos asociados a datasets reales de accidentes de tráfico. Esta clasificación permite justificar de forma explícita qué variables se utilizan, cuáles se descartan y cuáles requieren un tratamiento específico, asegurando coherencia entre el objetivo del proyecto y el pipeline de modelado.

Tipo A: variables con problemas de calidad del dato.

En este grupo se sitúan variables que describen el contexto del accidente, pero presentan inconsistencias habituales en datos reales (variantes semánticas, abreviaturas o categorías poco homogéneas). No se descartan por su valor informativo, aunque requieren limpieza y normalización para garantizar un uso consistente en el modelado.

Tipo B: variables con riesgo de fuga de información.

Aquí se agrupan variables cuya información se genera tras el accidente o está directamente ligada a su severidad. Su inclusión introduciría fuga de información, al incorporar señales no disponibles en un escenario real de predicción temprana; por este motivo se excluyen del entrenamiento, incluso si correlacionan con la variable objetivo.

Tipo C: variables identificativas o administrativas.

Este tipo engloba identificadores únicos y campos administrativos (número de reporte, identificadores de persona o vehículo, etc. Asimismo, incluye variables con un porcentaje muy elevado de valores ausentes, cuya cobertura es insuficiente para aportar señal robusta; por ello se excluyen del conjunto de modelado.

Tipo D: variables de alta cardinalidad o semántica débil.

Por último, se consideran variables con cardinalidad muy elevada o contenido poco estructurado. Aunque pueden aportar información contextual, su inclusión directa tiende a generar modelos inestables, por lo que requieren estrategias específicas de reducción, agrupación o codificación antes de incorporarse al modelado.

Tratamiento específico y variables derivadas.

Además de las tipologías anteriores, se identifican variables que no se utilizan directamente como predictores, sino que se emplean como variables auxiliares para la creación de nuevas características (por ejemplo, coordenadas geográficas o fechas). Estas variables se transforman, se utilizan para derivación y posteriormente se eliminan para evitar redundancias. El resultado de este proceso es un conjunto de nuevas variables creadas, diseñadas para capturar patrones relevantes de forma más robusta y alineada con el objetivo del modelo.

A modo de síntesis, la tabla resume la clasificación de variables según esta tipología, el tratamiento aplicado y las nuevas variables generadas durante el proceso de ingeniería de características.

Tipo A	Tipo B	Tipo C	Tipo D	Tratamiento específico	Nuevas variables
Agency Name	Injury Severity	Report Number	Road Name	Crash Date/Time	geo_cluster
Route Type	Vehicle Damage Extent	Local Case Number	Cross-Street Name	Latitude	multiple_crash
Collision Type	Vehicle First Impact	Person ID		Longitude	month
Vehicle Body Type	Driver At Fault	Vehicle ID		Vehicle Year	time_of_day
Vehicle Movement	Driver Substance	Non-Motorist Substance		Speed Limit	weekend
Vehicle Going Dir	Driver Distracted by	Location		Driverless Vehicle	Speed Limit Group
Traffic Control	Drivers License State	Circumstance		Parked Vehicle	Vehicle Age
Light	Vehicle Model	Off-Road Description			
Weather		Municipality			
Surface Condition		Related Non-Motorist			
Vehicle Make					

Variable objetivo

La variable objetivo del proyecto se define a partir de ACRS Report Type, que en origen clasifica los accidentes en tres categorías: Property Damage Crash, Injury Crash y Fatal Crash. Con el fin de alinear el planteamiento del problema con el objetivo operativo del trabajo, se reformula el problema como una clasificación binaria, agrupando Injury Crash y Fatal Crash en una única clase de daños físicos, y manteniendo Property Damage Crash como clase de daños exclusivamente materiales.

Esta decisión responde a criterios tanto operativos como metodológicos. Desde el punto de vista del uso real del sistema, el interés principal en una fase temprana del aviso es discriminar entre accidentes que probablemente requieran atención sanitaria prioritaria y aquellos que implican únicamente la gestión de daños materiales. En este contexto, la frontera relevante no es la distinción fina entre lesión y fallecimiento, sino la detección temprana de cualquier posible afectación física, coherente con la decisión práctica de movilizar recursos sanitarios (ambulancia) frente a recursos no sanitarios (grúa).

Desde el punto de vista estadístico, la categoría Fatal Crash presenta una frecuencia muy reducida en comparación con el resto de clases. Abordar el problema como una clasificación multiclase introduciría un alto riesgo de inestabilidad y baja robustez en la estimación del rendimiento para dicha categoría. Su agrupación con Injury Crash permite aprender patrones más sólidos asociados a la gravedad con daño físico, evitando que el comportamiento del modelo dependa de un número muy reducido de observaciones.

En consecuencia, se define la variable objetivo binaria como y = 1 para accidentes con daños físicos (Injury/Fatal) y y = 0 para accidentes con daños exclusivamente materiales (Property Damage), manteniendo coherencia con el objetivo general y facilitando la interpretación posterior de las salidas del modelo.

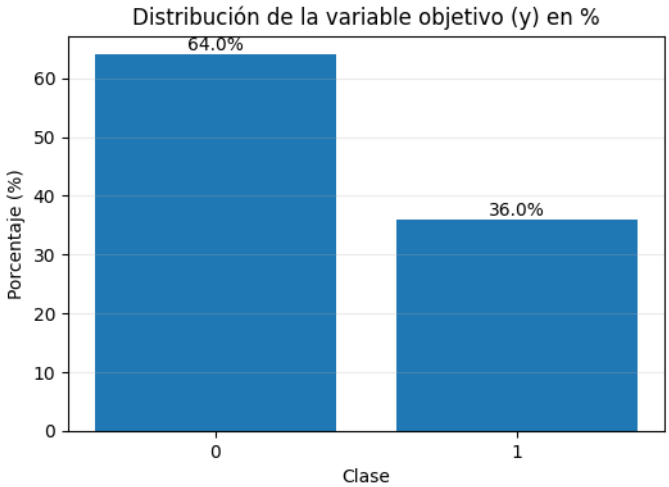

Estudios exploratorios

Con el objetivo de profundizar en la comprensión del fenómeno más allá del análisis univariado, se desarrollaron una serie de estudios exploratorios específicos orientados a analizar la relación entre distintas dimensiones del accidente y la severidad del mismo. Estos estudios no persiguen establecer relaciones causales, sino identificar patrones consistentes que ayuden a interpretar el comportamiento del modelo y contextualizar los resultados obtenidos posteriormente en la fase de modelado.

Cada estudio se centra en una dimensión complementaria del problema: (i) factores temporales y de contexto, (ii) características físicas y dinámicas del accidente, y (iii) interacción entre variables espaciales y condiciones del entorno. En conjunto, estos análisis permiten contrastar hipótesis razonables, detectar comportamientos no triviales y reforzar la coherencia entre el análisis exploratorio y las conclusiones del modelo predictivo.

A continuación, se presentan los tres estudios realizados, destacando los principales patrones observados y su relevancia para el caso de uso planteado.

Estudio 1. Análisis temporal: interacción entre franja horaria y fin de semana

Este estudio se centra en la identificación de patrones temporales relevantes para la severidad del accidente, analizando de forma conjunta la franja horaria (time_of_day) y la condición de fin de semana (weekend), y evaluando la proporción de casos severos en cada combinación. Este enfoque permite detectar si existen periodos del día con mayor criticidad y si estos patrones se modifican en función del tipo de jornada.

El análisis indica que la relación entre el momento del día y la severidad no es homogénea y presenta diferencias claras entre días laborables y fines de semana. La franja de madrugada concentra de forma consistente los valores más bajos, mientras que las franjas de mañana, tarde y noche presentan tasas más elevadas. Asimismo, se observa un comportamiento diferencial entre franjas: la tarde incrementa su severidad relativa durante el fin de semana, mientras que la noche muestra una reducción, lo que sugiere cambios en los patrones de movilidad, visibilidad y exposición al riesgo según el contexto temporal.

Desde el punto de vista del caso de uso planteado (triaje operativo entre envío de ambulancia o grúa), estos resultados indican que las variables temporales aportan señal predictiva relevante y, al estar disponibles en el registro inicial del siniestro, son adecuadas para su inclusión en el modelo. El uso de un umbral mínimo de observaciones refuerza además la interpretación de estos resultados como patrones consistentes y no como fluctuaciones debidas a baja frecuencia.

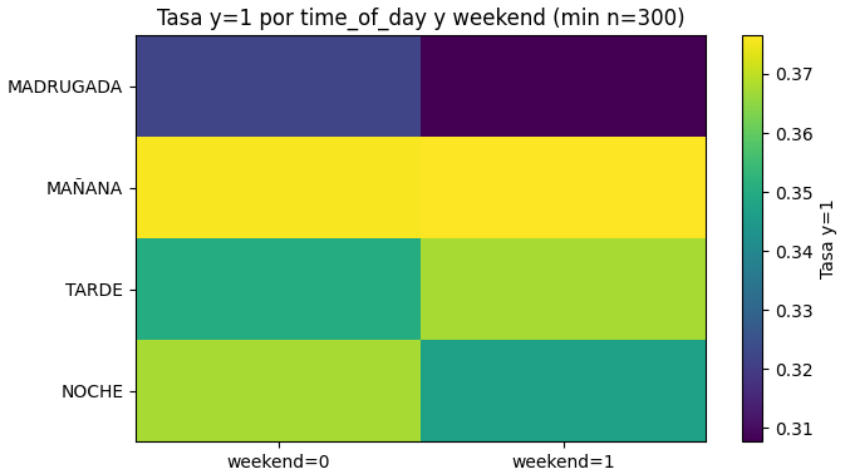

Estudio 2. Análisis espacial: interacción entre estado de la calzada y zona geográfica.

Se evalúa si el impacto del estado de la calzada sobre la severidad del accidente varía según la localización, analizando de forma conjunta la condición de la vía (Surface Condition) y la variable espacial agregada geo_cluster. El análisis se restringe a aquellas combinaciones con tamaño muestral suficiente, garantizando comparaciones estables entre estados de la calzada dentro de cada zona.

Se observa que el efecto de la calzada mojada no es homogéneo entre zonas. En varios geo_cluster las tasas de severidad asociadas a calzada seca y mojada aparecen prácticamente solapadas, lo que indica un impacto marginal del estado de la vía en dichas áreas. Sin embargo, en otros clusters se observa un desplazamiento más acusado bajo condiciones de calzada mojada, sugiriendo una mayor sensibilidad a escenarios de menor adherencia.

Asimismo, se identifican zonas que mantienen valores elevados de severidad con independencia del estado de la calzada, lo que apunta a áreas estructuralmente más severas, donde el riesgo parece estar dominado por características propias del entorno vial. Frente a estas, existen clusters que se mantienen sistemáticamente en rangos bajos y apenas modifican su comportamiento cuando la calzada está mojada. En conjunto, el análisis sugiere la coexistencia de dos perfiles diferenciados: zonas donde la severidad está principalmente condicionada por el contexto vial y zonas donde el estado de la calzada actúa como un factor amplificador del riesgo.

En términos de uso operativo (triaje ambulancia/grúa), este análisis justifica incorporar variables espaciales agregadas y el estado de la vía para discriminar escenarios con distinta probabilidad de daños físicos. La restricción por tamaño muestral mínimo refuerza que los patrones observados responden a señales estables y no a combinaciones poco frecuentes.

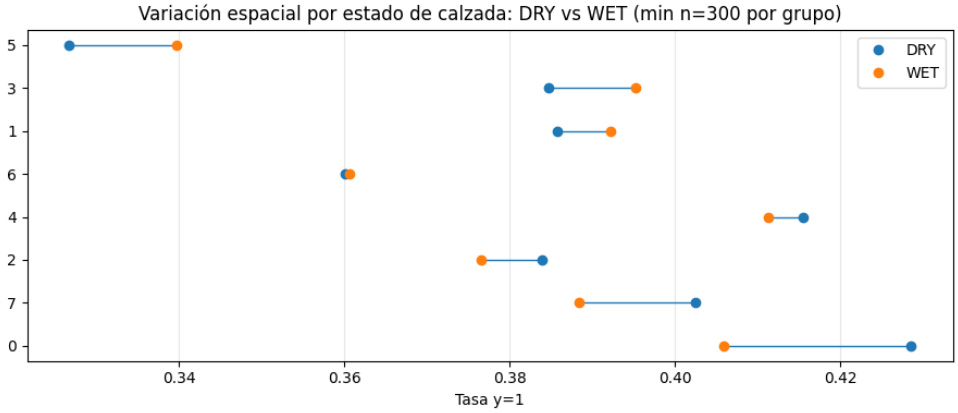

Estudio 3. Análisis de visibilidad: tipo de colisión y condiciones de iluminación.

En este último se examina cómo la severidad del accidente depende simultáneamente del tipo de colisión y de la condición de iluminación, analizando la interacción entre Collision Type y Light.

El análisis se restringe a aquellas combinaciones con tamaño muestral suficiente, garantizando que las comparaciones se basen en patrones estables y evitando interpretaciones derivadas de baja frecuencia.

Los resultados sugieren que la severidad depende simultáneamente del tipo de colisión y de la condición de iluminación, confirmando que ambos factores actúan de manera complementaria. Se observa que algunos mecanismos de choque mantienen tasas elevadas con independencia de la visibilidad, lo que sugiere que su severidad está dominada por la mecánica del impacto. En contraste, otros tipos de colisión presentan un incremento relativo de severidad en condiciones de menor visibilidad, especialmente en escenarios de iluminación reducida o crepuscular.

El análisis también pone de manifiesto una limitación inherente al dato: no todos los tipos de colisión están igualmente representados en las distintas condiciones de iluminación. Por este motivo, ciertas combinaciones se excluyen al no alcanzar el umbral mínimo de observaciones, evitando así la interpretación de tasas calculadas sobre muestras poco representativas.

De cara al triaje ambulancia/grúa, la interacción entre tipo de colisión e iluminación aporta información adicional para diferenciar situaciones con mayor probabilidad de lesiones. El filtrado por tamaño muestral asegura que las conclusiones se apoyan en tendencias consistentes y no en ruido estadístico.

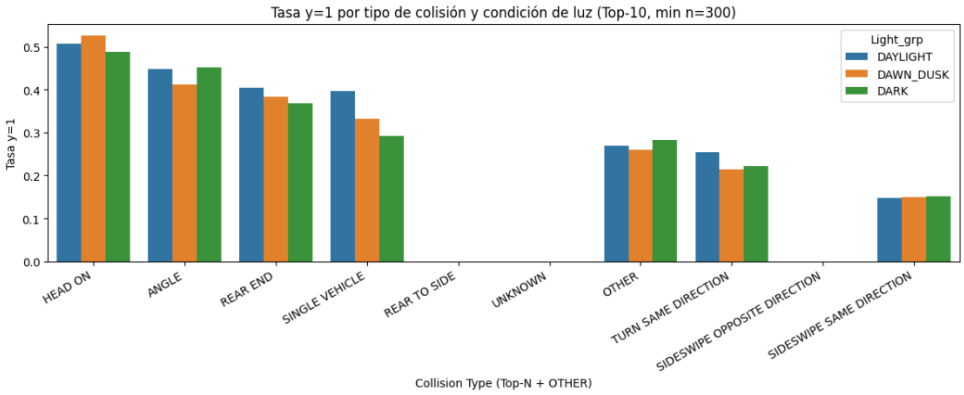

Conclusión.

En conjunto, los tres estudios exploratorios muestran que la severidad del accidente no responde a un único factor aislado, sino a la interacción entre dimensiones temporales, espaciales y de contexto, lo que justifica el enfoque multivariable adoptado en el modelo predictivo.

3. Modelado

Tras el análisis exploratorio, se aborda la fase de modelado predictivo con el objetivo de estimar la probabilidad de severidad del siniestro (y=1), entendida como la ocurrencia de daños físicos (lesiones o fallecimiento), a partir de la información disponible en el momento del accidente.

El proceso de modelado se plantea con un enfoque práctico y reproducible, coherente con los criterios definidos en la preparación de datos y orientado a obtener un sistema con capacidad real de generalización. En este sentido, el objetivo no es únicamente maximizar el rendimiento numérico, sino construir un modelo consistente con un escenario de uso: apoyo a la toma de decisiones tempranas en la asignación de recursos.

Dado que se trata de un problema de clasificación desbalanceada, la evaluación no se apoya exclusivamente en la exactitud global, sino en métricas que reflejan mejor la capacidad de discriminación y el equilibrio entre clases. Además, se adopta un criterio conservador alineado con el contexto operativo: los falsos negativos en la clase severa (y=1) se consideran especialmente críticos, al implicar el riesgo de infradetectar accidentes con daños físicos.

A partir de este planteamiento, el capítulo se estructura en tres etapas: (i) definición de un baseline trivial como referencia mínima, (ii) entrenamiento de un

modelo inicial y exploración de alternativas, y (iii) ajuste y comparación de modelos, incluyendo la optimización y la selección del umbral de decisión.

Para evitar fuga de información entre los conjuntos de entrenamiento y test, la partición del dataset se realiza a nivel de evento, garantizando que todos los registros asociados a un mismo accidente se asignen íntegramente a un único conjunto. Este criterio previene dependencias entre muestras y evita estimaciones optimistas del rendimiento al impedir que información del mismo siniestro esté presente simultáneamente en entrenamiento y evaluación.

3.1 Modelo baseline trivial como referencia mínima

Antes de abordar modelos con capacidad de aprendizaje, se establece un baseline trivial con el propósito de fijar una referencia mínima de rendimiento y evitar interpretaciones infladas en un contexto de desbalance entre clases. Este baseline representa la estrategia más simple posible: predecir siempre el desenlace más frecuente, clasificando todos los casos como accidentes con daños exclusivamente materiales (clase mayoritaria). Su valor es estrictamente metodológico: permite cuantificar el rendimiento que puede obtenerse sin extraer señal predictiva de las variables explicativas y, por tanto, define un umbral de comparación para evaluar la aportación real de los modelos posteriores.

Los resultados confirman las limitaciones esperables de este enfoque: el modelo presenta un recall nulo en la clase positiva (daños físicos, y=1) y una balanced accuracy coherente con un comportamiento sin capacidad discriminativa. En términos operativos, este baseline sería inadecuado para un escenario de triaje (priorización de ambulancia frente a grúa), ya que induce falsos negativos de forma sistemática, precisamente en los casos de mayor criticidad. En consecuencia, cualquier modelo candidato debe demostrar una mejora clara sobre este umbral mínimo, especialmente en su capacidad de detectar casos y=1, manteniendo al mismo tiempo un desempeño global equilibrado.

3.2 Modelo inicial: LightGBM

Como primer modelo con capacidad predictiva se selecciona LightGBM por su reconocida eficacia en problemas de datos tabulares y su eficiencia computacional, especialmente en contextos con un volumen elevado de observaciones y múltiples variables categóricas tras su codificación. Este modelo proporciona una referencia sólida desde la que evaluar mejoras posteriores y resulta adecuado para el escenario de uso planteado, donde se requiere una estimación ágil de la probabilidad de severidad para apoyar el triaje operativo.

Además, LightGBM permite establecer un equilibrio razonable entre rendimiento y control metodológico, facilitando la evaluación de la señal predictiva disponible en los datos sin introducir todavía complejidad excesiva en el pipeline.

3.3 Modelos alternativos

Con el fin de evaluar la robustez de los resultados y evitar conclusiones dependientes de un único algoritmo, se consideran modelos alternativos dentro de la familia de métodos de gradient boosting. La comparación entre enfoques permite comprobar si las mejoras obtenidas se deben a patrones estructurales del problema o a características específicas de un modelo concreto, manteniendo siempre el objetivo de viabilidad en un entorno operativo.

3.3.1 XGBoost

Se incorpora XGBoost como alternativa para contrastar el rendimiento frente a LightGBM y verificar si una implementación distinta del boosting ofrece ventajas en capacidad de generalización o en el equilibrio entre clases. Su inclusión responde a la necesidad de contar con un comparador consolidado en aplicaciones de clasificación tabular y de validar la estabilidad del desempeño bajo un enfoque competitivo y ampliamente utilizado en producción.

3.3.2 CatBoost

Finalmente, se evalúa CatBoost por su capacidad de tratar variables categóricas de forma más directa y robusta, lo que puede reducir la complejidad del preprocesado y limitar la sensibilidad del modelo a decisiones de codificación. Este aspecto resulta especialmente relevante en un problema con alta presencia de variables discretas y cardinalidades heterogéneas, donde un pipeline más simple puede aportar estabilidad, facilitar la reproducibilidad y mejorar la transferibilidad a un escenario de uso real.

3.4 Comparativa de modelos y selección del modelo candidato

La evaluación comparativa de LightGBM, XGBoost y CatBoost muestra un rendimiento muy similar en métricas globales —como ROC-AUC, PR-AUC y balanced accuracy— así como en F1, lo que sugiere que los tres algoritmos capturan un nivel de señal predictiva comparable y ofrecen capacidades de discriminación semejantes en términos agregados.

No obstante, la diferencia más relevante aparece en el desempeño sobre la clase positiva: al umbral inicialmente considerado, CatBoost alcanza un recall superior en y=1, recuperando una mayor proporción de siniestros con daños físicos, mientras que LightGBM y XGBoost quedan ligeramente por detrás. Esta distinción es metodológicamente significativa porque el objetivo del sistema se alinea con un escenario de triaje, en el que el coste de error es asimétrico: un falso positivo suele traducirse en un coste operativo (por ejemplo sobreactuación), mientras que un falso negativo implica el riesgo de no priorizar un caso potencialmente severo, con consecuencias operativas y sociales más graves.

En consecuencia, se selecciona CatBoost como modelo candidato para la fase final, al ofrecer la mejor relación relativa en recall sin penalizar de forma apreciable el rendimiento global. Además, dado que la decisión final puede adaptarse a la política operativa mediante el ajuste del umbral de clasificación, esta selección se realiza de forma coherente con el uso previsto del modelo: maximizar la recuperación de casos y=1 manteniendo un equilibrio razonable en el conjunto de métricas.

	Modelo	Threshold	Precision (pos)	Recall (pos)	F1 (pos)	F2 (pos)	Balanced Acc	ROC-AUC	PR-AUC
0	CatBoost	0.500000	0.4808	0.7345	0.5812	0.6644	0.6391	0.6971	0.5433
1	XGBoost	0.500000	0.4881	0.6752	0.5666	0.6271	0.6339	0.6901	0.5352
2	LightGBM	0.500000	0.4912	0.6635	0.5645	0.6200	0.6340	0.6903	0.5360

3.5 Optimización del modelo

Una vez seleccionado CatBoost como modelo candidato, se exploró la optimización de hiperparámetros mediante búsqueda aleatoria con validación cruzada, con el objetivo de comprobar si era posible obtener mejoras consistentes sin comprometer la generalización. El mejor resultado alcanzado en este proceso fue

un ROC-AUC medio en validación cruzada de aproximadamente 0,69, un valor que no representa una mejora clara respecto al rendimiento observado con la configuración inicial.

Además, debe considerarse que este resultado se obtiene bajo un esquema de evaluación distinto al empleado para la comparación final (promedio en validación cruzada frente a métricas estimadas sobre el conjunto de test). En ausencia de una ganancia inequívoca y consistente bajo un marco comparable, se evita introducir complejidad adicional que podría traducirse en variabilidad o sobreajuste a un procedimiento de validación particular.

En consecuencia, se decide mantener la configuración base de CatBoost como modelo final por dos razones principales: ofrece un rendimiento competitivo en la evaluación del proyecto y también porque presenta una configuración más simple y estable, lo que facilita su reproducibilidad, mantenimiento y despliegue. Esta decisión es coherente con el escenario de uso planteado (triaje), donde se prioriza la robustez y la fiabilidad del sistema por encima de mejoras marginales no garantizadas.

3.6 Ajuste del umbral de decisión

El modelo seleccionado (CatBoost) no produce directamente una decisión categórica, sino una probabilidad estimada de que el siniestro corresponda a la clase positiva (daños físicos: Injury/Fatal, y=1). Para transformar esa probabilidad en una decisión binaria es necesario fijar un umbral de decisión (threshold). Aunque el valor convencional de 0,50 ofrece una regla simple, no siempre es el más adecuado cuando el modelo se integra en un proceso operativo con costes de error asimétricos.

En este trabajo, el problema se interpreta como un triaje: se busca priorizar la identificación de accidentes con probabilidad de daños físicos, reduciendo el riesgo de no activar recursos sanitarios cuando podrían ser necesarios. Sin embargo, un enfoque excesivamente conservador —orientado a maximizar el recall de manera aislada— puede aumentar de forma significativa los falsos positivos, es decir, activaciones preventivas en casos que finalmente serían daños exclusivamente materiales. En un entorno real, este comportamiento impacta en la eficiencia del sistema, ya que movilizar recursos sanitarios sin necesidad supone un coste operativo y puede afectar a la disponibilidad ante incidentes más graves.

Por ello, el ajuste del umbral se plantea como una decisión operativa, cuyo objetivo es gestionar el compromiso entre:

Falsos negativos (FN): siniestros con daños físicos no detectados (error crítico en triaje).

Falsos positivos (FP): activaciones innecesarias (coste operativo y saturación potencial).

A partir de la evaluación del comportamiento del modelo en distintos valores del threshold, se selecciona un umbral recomendado que mantiene una capacidad elevada de detección de la clase positiva, reduciendo a la vez el volumen de activaciones innecesarias.

El análisis confirma el trade-off esperado entre precisión y recall en la clase Injury/Fatal: umbrales más bajos incrementan la recuperación de casos y=1, pero elevan el número de falsos positivos; umbrales más altos reducen activaciones innecesarias, a costa de perder sensibilidad. En este contexto, se recomienda un threshold de 0,54, al representar un equilibrio operativo adecuado: es el primer valor que sitúa la precisión de la clase positiva por encima de 0,50, reduce falsos positivos

respecto a 0,53 y mantiene un recall todavía elevado (≈0,63). De este modo, el sistema conserva una alta capacidad de triaje minimizando el riesgo de infradetección sin comprometer la operatividad por exceso de activaciones.

Finalmente, la aplicación desarrollada permite ajustar dinámicamente el umbral para adaptarlo a condiciones variables de disponibilidad de recursos (por ejemplo, priorizar recall en contextos de máxima cautela o priorizar precisión cuando los recursos son limitados), lo que refuerza la orientación práctica del sistema como herramienta de apoyo a la decisión.

	thr	accuracy	precision_1	recall_1	f1_1	bal_acc	FP	FN	TP	TN
0	0.53	0.631820	0.497006	0.658907	0.566618	0.637569	9912	5070	9794	15916
1	0.54	0.637890	0.503463	0.630786	0.559978	0.636382	9247	5488	9376	16581
2	0.55	0.643960	0.510776	0.599502	0.551594	0.634523	8535	5953	8911	17293
3	0.56	0.648039	0.516644	0.565931	0.540166	0.630612	7870	6452	8412	17958

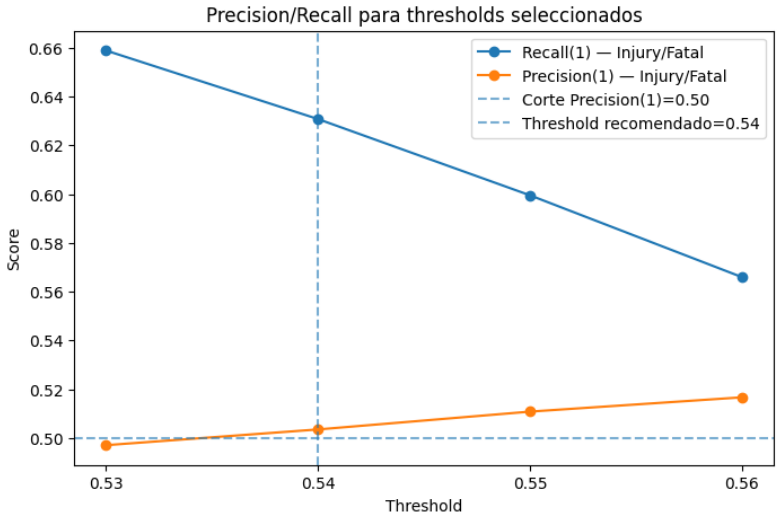

4. Interpretabilidad del modelo mediante SHAP

Con el fin de dotar al modelo de transparencia y facilitar su uso en un contexto de apoyo a decisiones, se emplean explicaciones basadas en SHAP. Esta metodología permite descomponer la predicción en contribuciones atribuibles a cada variable, ofreciendo interpretabilidad tanto a nivel global (qué factores pesan más en general) como local (por qué un caso concreto recibe una determinada predicción). Conviene remarcar que estas explicaciones describen el comportamiento del modelo y sus patrones aprendidos, y no deben interpretarse como relaciones causales.

a) Importancia global

El análisis global (media del valor absoluto de SHAP) muestra que la predicción de severidad está dominada por variables estrechamente vinculadas a la dinámica del siniestro, destacando especialmente Collision Type, junto con Vehicle Body Type, la presencia de multiple_crash y Vehicle Movement. Este resultado sugiere que, para el modelo, la mayor parte de la información discriminativa proviene de cómo se produce el impacto y de la configuración del evento, más que de factores periféricos.

En un segundo nivel aparecen variables de contexto vial y temporal —como Speed Limit Group, Traffic Control, month, time_of_day y geo_cluster—, con un papel complementario como moduladores del riesgo. En cambio, variables ambientales (por ejemplo Weather o Light) y determinadas variables administrativas presentan un peso relativo menor.

En conjunto, este patrón es coherente con el escenario de triaje planteado: el modelo prioriza señales próximas al mecanismo del accidente, que son las más informativas para anticipar la probabilidad de daños físicos.

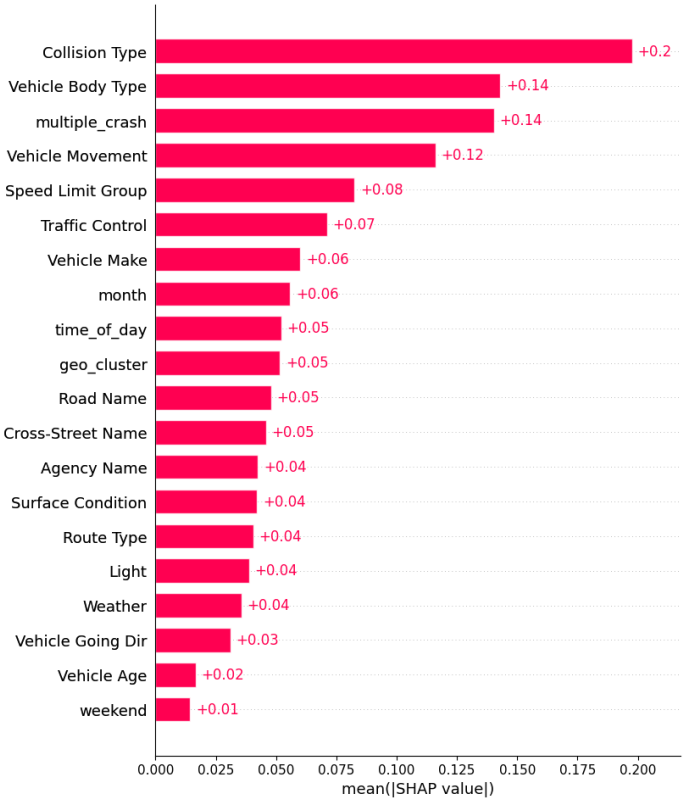

b) Distribución del efecto (beeswarm)

La representación tipo beeswarm permite analizar no solo qué variables importan, sino también cómo varía su efecto entre observaciones. Las variables con mayor importancia global muestran una dispersión elevada en sus valores SHAP, lo que indica que su impacto no es uniforme: una misma característica puede contribuir en sentidos opuestos dependiendo del contexto del siniestro y de la combinación con otras variables.

Este comportamiento es especialmente visible en variables relacionadas con el tipo de colisión, tipo de vehículo y colisiones múltiples, lo que apunta a la existencia de interacciones implícitas aprendidas por el modelo. Por el contrario, las variables temporales y espaciales tienden a concentrar su efecto alrededor de contribuciones más moderadas, actuando más como ajuste contextual que como detonante principal.

En términos interpretativos, el modelo no opera mediante reglas simples, sino mediante patrones dependientes del contexto, coherentes con la naturaleza multifactorial de la severidad en accidentes.

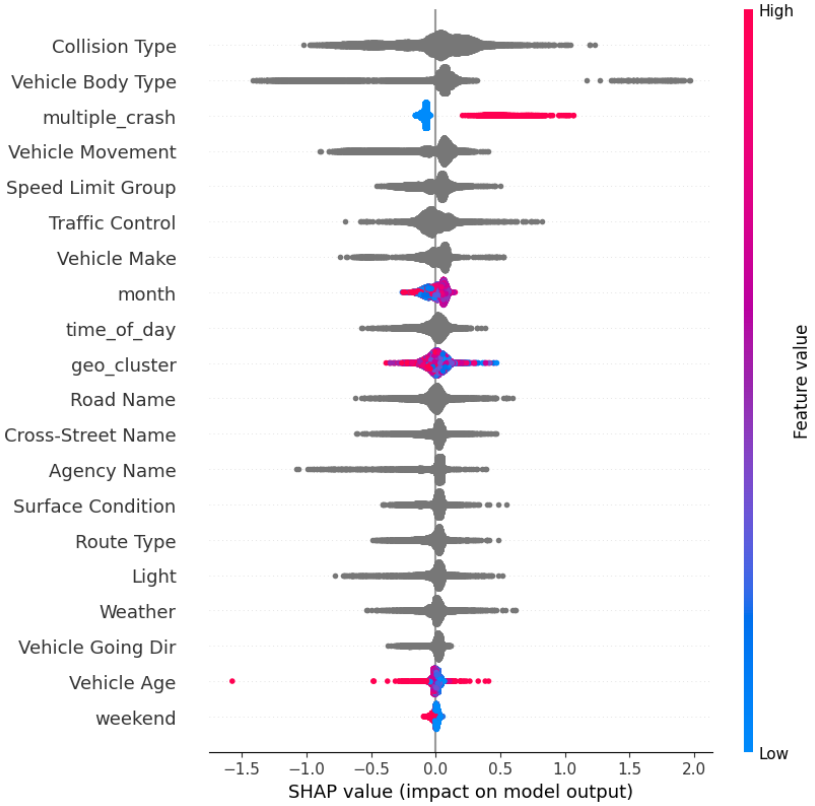

c) Explicación local (waterfall)

Este gráfico descompone la predicción del modelo para un caso individual, mostrando cómo cada variable contribuye a mover la estimación desde un valor base hasta la predicción final. Las barras en rojo representan factores que incrementan la severidad estimada, mientras que las azules la reducen.

En el ejemplo mostrado, la predicción queda principalmente impulsada por variables relacionadas con el mecanismo del impacto y el contexto inmediato del accidente. Destacan especialmente factores como el tipo de colisión, el límite de velocidad del tramo y la maniobra del vehículo, que empujan la estimación hacia una mayor probabilidad de severidad. También aparecen aportes adicionales asociados al control de tráfico y a la zona geográfica, junto con variables ambientales y de vía que actúan como refuerzo contextual.

Al mismo tiempo, algunas variables actúan en sentido contrario y moderan la predicción, reflejando que no todos los elementos del registro apuntan hacia un escenario más grave. Estos efectos negativos funcionan como ajustes que compensan parcialmente los impulsores principales, sin llegar a cambiar el resultado global.

Este tipo de explicación resulta especialmente relevante en un escenario de apoyo a la toma de decisiones, ya que permite justificar de forma transparente porqué el modelo considera un caso como más o menos grave, facilitando la confianza del usuario y la interpretabilidad operativa del sistema.

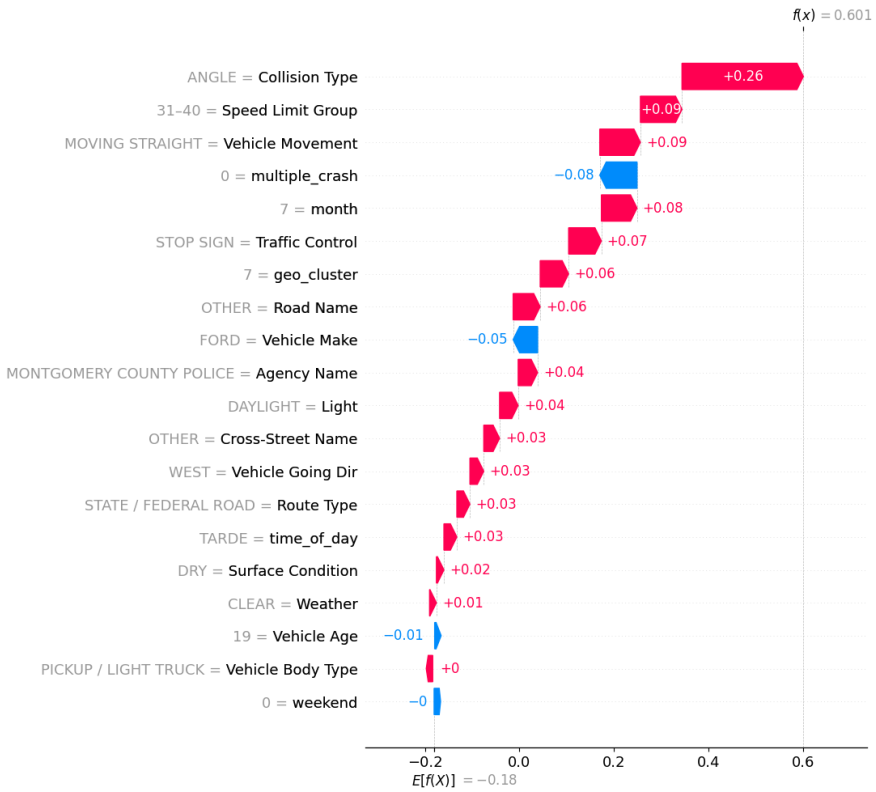

d) SHAP dependence

Finalmente, el análisis de dependencia examina cómo varía el efecto de Collision Type a lo largo de sus categorías y permite observar que no todos los mecanismos de colisión contribuyen de igual modo a la predicción: algunos tienden a aumentar la probabilidad estimada de severidad, mientras que otros la reducen, confirmando que el modelo discrimina entre escenarios de impacto con diferente nivel de riesgo.

La coloración por Speed Limit Group sugiere además que el efecto del tipo de colisión puede modularse por el contexto de velocidad, indicando que el modelo captura combinaciones relevantes (por ejemplo, ciertos tipos de colisión pueden asociarse a mayor riesgo en entornos de mayor velocidad). Este análisis aporta valor al pasar de "qué variables importan" a "en qué condiciones importan", reforzando la lectura conjunta del siniestro y su entorno.

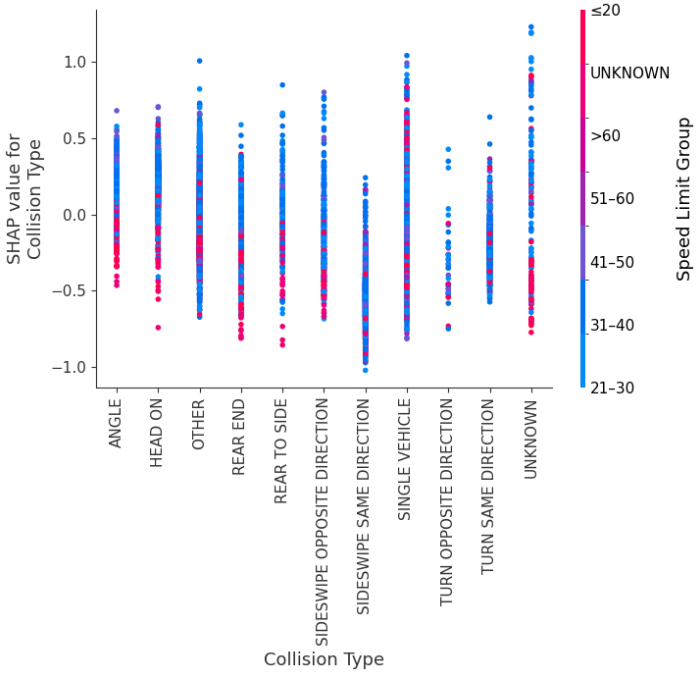

5. Productivización del modelo

5.1 Persistencia del modelo y consistencia de entrada

Una vez seleccionado el modelo final, se procede a su preparación para su utilización con nuevos casos, trasladándolo desde el entorno de entrenamiento a un flujo de inferencia desacoplado.

El modelo se persiste en formato nativo de CatBoost (.cbm), junto con los artefactos necesarios para garantizar la coherencia en el preprocesado (orden de variables y categorías válidas). Esto asegura que cualquier nuevo registro introducido en el sistema sea transformado bajo los mismos criterios que los datos utilizados durante el entrenamiento.

De este modo, el modelo validado puede reutilizarse sin necesidad de reentrenamiento, quedando preparado para recibir nuevos valores y devolver una predicción.

5.2 Interfaz de consumo

Como capa de interacción con el usuario final, se implementa una aplicación en Streamlit que permite introducir las variables disponibles en el momento del aviso inicial y obtener como salida la probabilidad estimada de severidad.

La aplicación carga el modelo persistido y transforma las entradas conforme al mismo flujo utilizado en entrenamiento. A partir de la probabilidad generada, se aplica la regla de decisión definida en el apartado 3.6 mediante un umbral configurable, lo que permite traducir la estimación continua en una clasificación operativa.

Esta integración convierte la salida probabilística del modelo en una herramienta directamente utilizable en un contexto de triaje temprano, manteniendo siempre la decisión final bajo criterio humano.

5.3 Caso práctico de uso

Para ilustrar la utilización del sistema en un contexto realista, se plantea un escenario típico de gestión de emergencias. Un ciudadano presencia un accidente (o llega en los instantes inmediatamente posteriores) y contacta con el servicio de emergencias. En esa fase inicial, la información disponible suele ser parcial, pero permite describir el suceso de forma preliminar (tipo de colisión, condiciones del entorno, franja horaria aproximada y ubicación general, entre otros).

Con los datos recopilados durante la llamada, el operador introduce los valores en la aplicación, configurada con el umbral de decisión adecuado al contexto operativo (por ejemplo, en función de la disponibilidad de recursos o del nivel de precaución deseado). A partir de esta entrada, el sistema devuelve una estimación probabilística de severidad y una recomendación asociada, que puede emplearse como señal adicional para apoyar el triaje temprano y priorizar recursos cuando la información es ambigua o existen múltiples incidentes simultáneos.

En todo caso, el sistema no pretende sustituir el juicio profesional, sino complementarlo, aportando un criterio cuantitativo coherente y ajustable al escenario.

5.4 Validación post-prueba

Durante la prueba funcional de la aplicación se identificó la coexistencia de registros con time_of_day = NOCHE y Light = DAYLIGHT, una combinación que, desde un punto de vista intuitivo, podría interpretarse como inconsistente. Dado el impacto que este tipo de configuraciones puede tener tanto en la interpretabilidad del modelo como en la confianza en el sistema de triaje, se analizó su origen y significado dentro del contexto del dataset.

El análisis muestra que esta combinación no responde a errores de calidad del dato ni a valores residuales, sino a un patrón estructural derivado de la definición operativa de las variables temporales y del contexto estacional. En particular, time_of_day se construye mediante una discretización horaria basada en umbrales fijos, mientras que Light refleja la condición de iluminación reportada en el momento del accidente. Esta diferencia conceptual permite que ambas categorías coexistan en determinadas franjas horarias.

La distribución temporal de estos casos se concentra en horas de última tarde y presenta una clara estacionalidad, con mayor presencia en los meses de primavera y verano. Este comportamiento es coherente con escenarios en los que, pese a haberse superado el umbral horario definido como "noche", persiste la luz diurna debido a la duración del día en dichas épocas del año.

En consecuencia, la combinación NOCHE + DAYLIGHT se considera semánticamente coherente dentro del marco de representación temporal adoptado. Por este motivo, no se aplican correcciones ni filtrados automáticos sobre estos registros. Ambas variables se mantienen en el modelo, al aportar información complementaria y relevante desde el punto de vista analítico y predictivo.

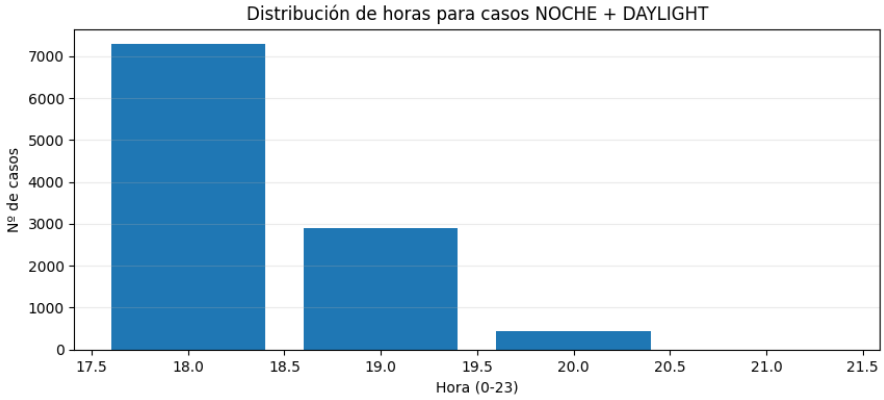

5.5 Consideraciones para entorno operativo

En un escenario real, sería recomendable complementar la solución con un proceso de seguimiento que permita verificar que el modelo mantiene su rendimiento con el paso del tiempo. En particular, convendría monitorizar tanto el desempeño (métricas y tasa de alertas generadas) como la estabilidad de las variables de entrada, ya que cambios en el patrón de los avisos o en el contexto vial pueden afectar a la validez de las predicciones.

Asimismo, el umbral de decisión debería revisarse periódicamente, al tratarse de un parámetro ligado a la política operativa y a la disponibilidad de recursos. Finalmente, en caso de detectarse degradación del rendimiento o cambios sostenidos en la distribución de los datos, sería necesario plantear recalibración del umbral y/o reentrenamiento del modelo con información actualizada.

6. Conclusión

El presente trabajo ha permitido confirmar la viabilidad técnica de utilizar técnicas de Machine Learning como apoyo al triaje de emergencias en siniestros viales. Los resultados muestran que es posible anticipar la gravedad de un accidente —discriminando entre daños materiales y físicos— utilizando exclusivamente información disponible en la notificación inicial, sin depender de evaluaciones posteriores. Frente a un baseline trivial, el modelo final basado en CatBoost es capaz de capturar señal predictiva relevante en un problema intrínsecamente complejo, apoyando la idea de que la severidad depende de la interacción no lineal entre variables asociadas a la mecánica del impacto y al contexto del accidente.

Uno de los aportes metodológicos más relevantes del estudio ha sido abordar el problema no solo como un ejercicio de clasificación, sino como una decisión operativa

condicionada por recursos limitados. La estrategia se estructuró en dos fases para gestionar el trade-off del caso de uso: en primer lugar, priorizando un modelo con alta capacidad de detección (recall) de la clase severa para reducir falsos negativos; y, en segundo lugar, ajustando el umbral de decisión para controlar el volumen de falsas alarmas y mejorar la eficiencia operativa. De este modo, se demuestra que puede alcanzarse un equilibrio entre sensibilidad y carga operativa, manteniendo una tasa elevada de detección de casos graves sin incrementar de forma innecesaria las activaciones.

Asimismo, el análisis de interpretabilidad mediante SHAP ha sido determinante para validar la coherencia interna del sistema y reducir el riesgo de "caja negra". Las explicaciones locales y globales reflejan un peso predominante de variables ligadas a la configuración del siniestro, mientras que los factores ambientales actúan como moduladores del riesgo, reforzando la confianza en el modelo como herramienta de apoyo al juicio experto. Finalmente, la implementación del prototipo interactivo completa el ciclo del proyecto, mostrando la factibilidad de integrar el modelo y sus artefactos de preprocesado en una aplicación de inferencia orientada a uso en tiempo real.

7. Bibliografía y Referencias

Fuente de Datos

- The Home of the U.S. Government's Open Data. Disponible en: https://data.gov/

Librerías y Documentación Técnica

- Scikit-learn Developers. (2024*). User Guide: Machine Learning in Python.* Disponible en: https://scikit-learn.org/stable/user_guide.html
- XGBoost Developers. (2024). *XGBoost Documentation*. Disponible en: https://xgboost.readthedocs.io/
- LightGBM Developers. (2024*). LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. Microsoft Corporation. Disponible en: https://lightgbm.readthedocs.io/
- Lundberg, S. (2024*). SHAP (SHapley Additive exPlanations) Documentation*. Disponible en: https://shap.readthedocs.io/

Libros y Manuales de Referencia

- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly Media.*
- Molnar, C. (2022). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. Disponible en:* https://christophm.github.io/interpretable-ml-book/
- McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython. O'Reilly Media.*